Zadanie 1: optymalizacja gradientowa

Grupa: Anna Moroń, Kalina Rączka, Emilia Sarna

Termin realizacji: 16 marca 2026

Wybierz jedną z testowych funkcji o dwóch zmiennych do optymalizacji (z https://en.wikipedia.org/wiki/Test_functions_for_optimization) (oprócz "sphere function", "Matyas function" i "Booth function").

Zadanie do oddania przez MS Teams. Do oddania: kod oraz krótkie sprawozdanie w PDF (można na przykład przy użyciu `quarto render notebook.ipynb --to pdf`).

Na 3.0

Do realizacji:

1. Weź implementację optymalizacji gradientowej z zadania z ostatnich ćwiczeń. Zwróć uwagę na:
    1. Punkt powinien być reprezentowany jako tablica (np. `Vector`), a nie jako pojedyncze zmienne.
    2. Funkcja optymalizowana powinna być funkcją, która przyjmuje wektor i zwraca liczbę rzeczywistą.
    3. Gradient powinien być wektorem o tym samym wymierze co punkt.
2. Wylosuj 10 punktów z dziedziny przeszukiwania z tabelki. Dla każdego z nich przeprowadź 100 kroków optymalizacji metodą największego spadku ze stałym krokiem. Narysuj wykres zależności wartości funkcji optymalizowanej od kroku optymalizacji.
3. Przeprowadź procedurę dla kilku kroków. Spróbuj zilustrować brak zbieżności, szybką zbieżność i powolną zbieżność.

Możesz skorzystać z kodu pod zadaniem na 5.

Na 4.0

Do realizacji:

1. Punkty z zadania na 3.0.
2. Zamień stały krok z poprzedniego zadania na warunek wystarczającego spadku Armijo. Jako początkowy bracket przyjmij $[0, 1]$. Porównaj zbieżność metody o stałym kroku z przeszukiwaniem liniowym za pomocą wykresów wartości w konkretnym kroku uśrednione między poszczególnymi punktami początkowymi. Porównaj wyniki dla 6 różnych kombinacji parametrów metody Armijo.

Na 5.0

Do realizacji:

1. Punkty z zadania na 4.0.
2. Zamień stały bracket $[0, 1]$ z poprzedniego punktu na metodę automatycznie określającą bracket (przykład z wykładu). Porównaj wyniki z poprzednią metodą dla minimum 6 zestawów parametrów bracketingu.

Zadania na 3.0:

Funkcja: Three-hump camel function

$f(x, y) = 2x^2 - 1.05x^4 + \frac{x^6}{6} + xy + y^2$

Ma globalne minimum w punkcie $(0, 0)$ z wartością $f(0, 0) = 0$.

```
function f(x::Vector)
    return 2*x[1]^2 - 1.05*x[1]^4 + x[1]^6/6 + x[1]*x[2] + x[2]^2
end

# Gradient funkcji
function grad_f!(g::Vector, x::Vector)
    g[1] = 4*x[1] - 4.2*x[1]^3 + x[1]^5 + x[2]
    g[2] = x[1] + 2*x[2]
end

# Dziedzina: [-5, 5] x [-5, 5]
const DOMAIN = (-5.0, 5.0)
```

```
(-5.0, 5.0)
```

Przykładowe wartości analizowanej funkcji:

```julia
println("f(1.0, 1.0) = ", f([1.0, 1.0]))
println("grad_f(1.0, 1.0) = ", grad_f!([0.0, 0.0], [1.0, 1.0]))

println("f(0.0, 0.0) = ", f([0.0, 0.0]))
println("grad_f(0.0, 0.0) = ", grad_f!([0.0, 0.0], [0.0, 0.0]))
```

```
f(1.0, 1.0) = 3.1166666666666667
grad_f(1.0, 1.0) = 3.0
f(0.0, 0.0) = 0.0
grad_f(0.0, 0.0) = 0.0
```

Wizualizacja funkcji:

```julia
using LinearAlgebra
using Plots
using Random

# Wizualizacja funkcji
xs = range(DOMAIN[1], DOMAIN[2], length=100)
ys = range(DOMAIN[1], DOMAIN[2], length=100)
zs = [f([x, y]) for y in ys, x in xs]
zs_log = log10.(zs .+ eps())   # logarytm dla czytelności

contourf(xs, ys, zs_log, color=:plasma, title="Three-hump camel function",
    xlabel="x", ylabel="y", zlabel="log10(f(x,y))", size=(600, 550))
```

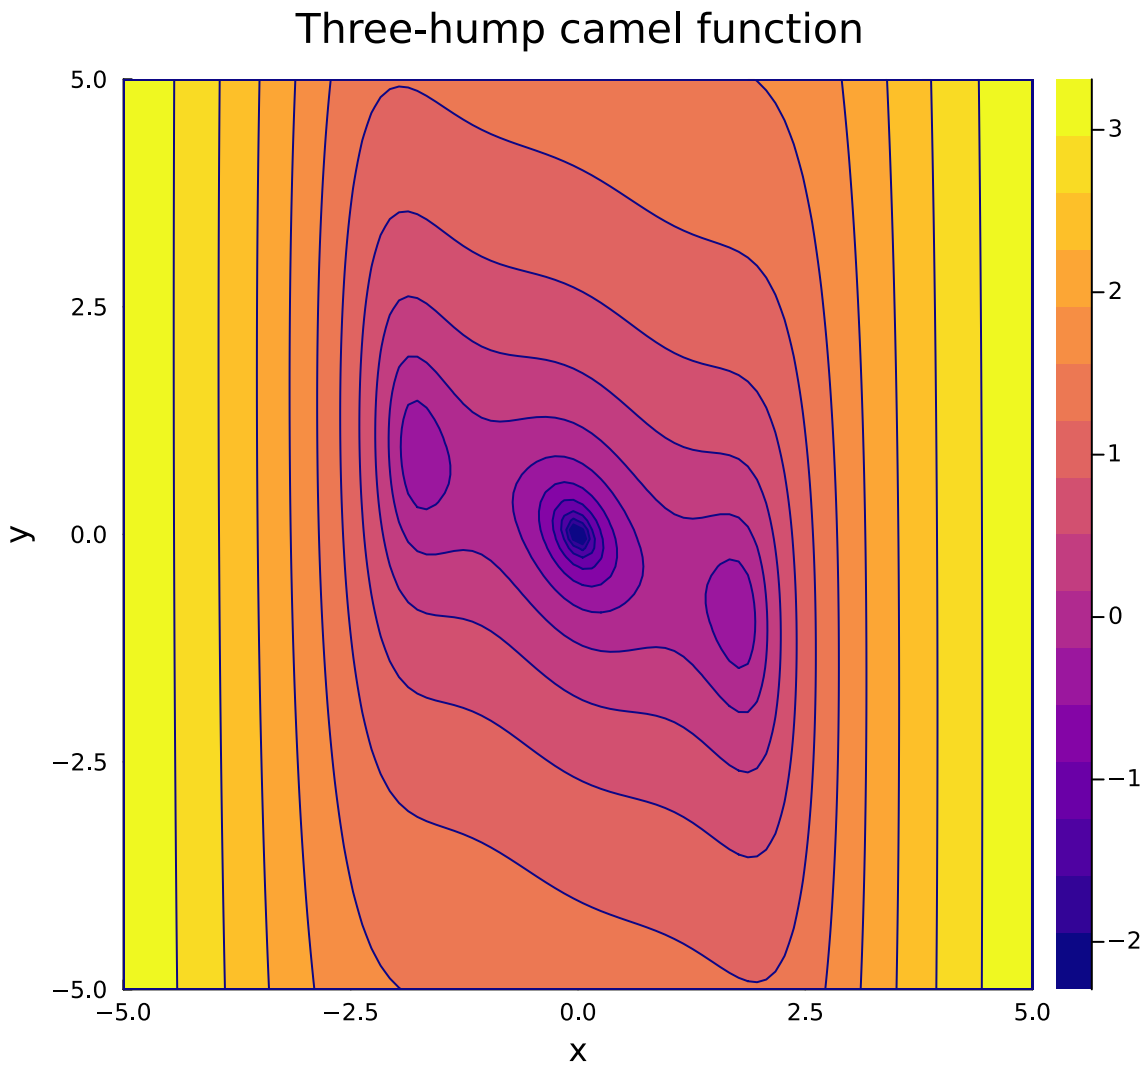

Optymalizacja gradientowa

```
function my_optimize_const_step(cost_data, grad_data, x0;
        step=1e-5, maxiter=100000, tol=1e-6)

    x = copy(x0)
    g = similar(x)

    fx = cost_data(x)
```

```
    if !isfinite(fx)
        error("cost_data(x0) is not finite (got $fx). Choose a valid x0 / fix
                cost domain.")
    end

    for k in 1:maxiter
        grad_data(g, x)
        if any(!isfinite, g)
            error("Gradient became non-finite at iter=$k")
        end

        # Jeśli sie przesuwany o bardzo mały gradient
        if norm(g) < tol
            return x
        end

        x .= x .- step .* g
    end
    # println("Exceeded maxiter=$maxiter without convergence")
    return x
end
```

```
my_optimize_const_step (generic function with 1 method)
```

Generowanie punktów

```
# zapisywanie historii punktów
function optimize_with_history(cost, grad!, x0; step=0.01, maxiter=100, tol=1e-6,
            optimization_function=my_optimize_const_step)
    x = copy(x0)
    history = Float64[]
    for k in 1:maxiter
        push!(history, cost(x))
        x = optimization_function(cost, grad!, x; step=step, maxiter=1, tol=tol)
    end
    push!(history, cost(x))
    return x, history
end

# Losowanie 10 punktów z dziedziny DOMAIN × DOMAIN
```

```julia
Random.seed!(42)
function rand_uniform(a, b)
    return [rand() * (b - a) + a, rand() * (b - a) + a]
end

starting_points = [rand_uniform(DOMAIN[1], DOMAIN[2]) for _ in 1:10]
println("Wylosowane punkty startowe:")
for (i, p) in enumerate(starting_points)
    println("  $i: x = $(round.(p, digits=2))")
end
```

```
Wylosowane punkty startowe:
  1: x = [1.29, -0.5]
  2: x = [-0.23, 2.03]
  3: x = [1.73, -3.34]
  4: x = [1.13, 1.68]
  5: x = [-0.43, -2.01]
  6: x = [1.61, 1.39]
  7: x = [-1.57, -2.32]
  8: x = [0.16, -4.1]
  9: x = [-2.27, -3.08]
  10: x = [-0.76, -0.15]
```

100 kroków optymalizacji dla każdego punktu, stały krok = 0.01

```julia
step_size = 0.01
all_histories = []

for x0 in starting_points
    _, hist = optimize_with_history(f, grad_f!, x0, step=step_size, maxiter=100)
    push!(all_histories, hist)
end

# Wykres
p = plot(title="Zbieżność optymalizacji (krok = $step_size)",
         xlabel="Iteracja", ylabel="f(x)", legend=:topright)
for (i, hist) in enumerate(all_histories)
    plot!(p, 0:100, hist, label="Punkt $i", alpha=0.7)
end
display(p)
```

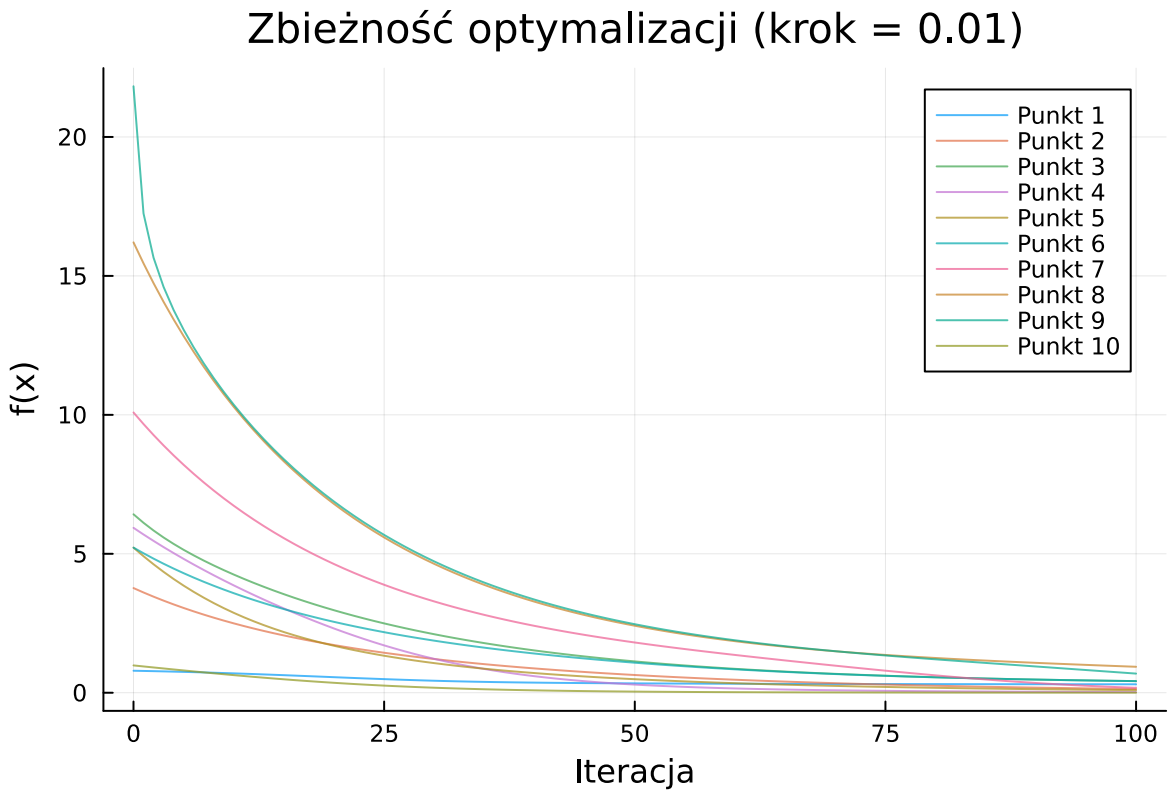

Porównanie różnych kroków dla jednego punktu:

```
step_sizes = [0.6, 0.1, 0.01, 0.001]  # różne kroki
labels = ["Brak zbieżności (0.6)", "Szybka zbieżność (0.1)",
          "Średnia zbieżność (0.01)", "Powolna zbieżność (0.001)"]


test_point = starting_points[6]

p2 = plot(title="Wpływ wielkości kroku na zbieżność",
          xlabel="Iteracja", ylabel="f(x)", legend=:topright)

for (step, label) in zip(step_sizes, labels)
    _, hist = optimize_with_history(f, grad_f!, test_point, step=step, maxiter=100)
    hist_clipped = clamp.(hist, -1e6, 1e6)
    plot!(p2, 0:100, hist_clipped, label=label, linewidth=2)
end
display(p2)
```

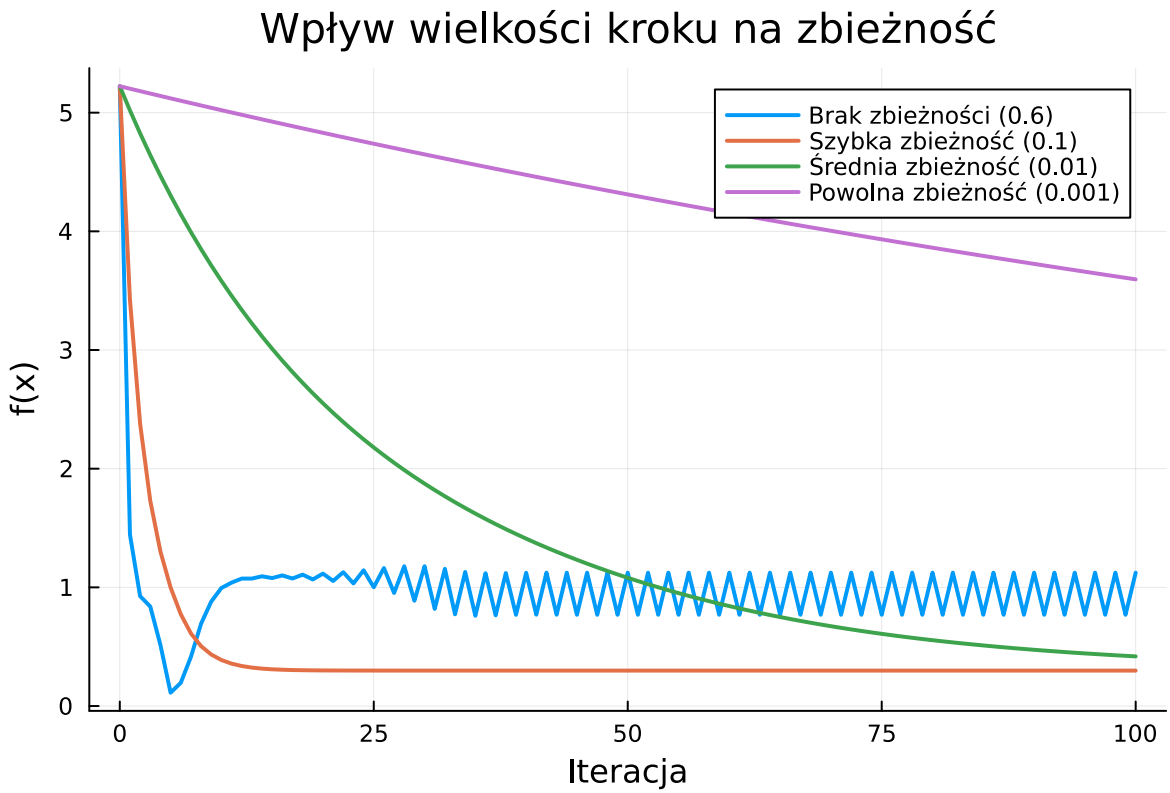

Wnioski

Analiza wpływu wielkości kroku:

- Krok = 0.6 - Zbyt duży krok powoduje brak zbieżności lub oscylacje. Algorytm "przeskakuje" minimum.
- Krok = 0.1 - Odpowiedni krok dla szybkiej zbieżności do minimum.
- Krok = 0.01 - Średnia zbieżność.
- Krok = 0.001 - Zbyt mały krok, powolna zbieżność, algorytm wymaga wielu iteracji.

Zadania na 4.0:

Przeszukiwanie liniowe z warunkiem Armijo

```
# Bracket: [0, 1] → startujemy od alpha=1 i zmniejszamy
function armijo_line_search(cost, x, g; c=0.1, rho=0.5)
    d = -g                          # kierunek najstromszego spadku
```

```
    fx = cost(x)
    slope = dot(g, d)           # = -||g||² (zawsze < 0)
    alpha = 1.0                 # górny koniec bracketu [0, 1]

    while true
        if isfinite(cost(x .+ alpha .* d)) && cost(x .+ alpha .* d) <= fx + c * alpha * slope
            break
        end
        alpha *= rho
        alpha < 1e-16 && break
    end
    return alpha
end

# Optymalizacja metodą z warunkiem Armijo
function optimize_armijo_step(cost_data, grad_data, x0;
        step=nothing, maxiter=100, tol=1e-6, c=0.1, rho=0.5)

    x = copy(x0)
    g = similar(x)

    fx = cost_data(x)
    if !isfinite(fx)
        error("cost_data(x0) is not finite (got $fx).")
    end

    for k in 1:maxiter
        grad_data(g, x)
        any(!isfinite, g) && error("Gradient became non-finite at iter=$k")
        norm(g) < tol && return x
        alpha = armijo_line_search(cost_data, x, g; c=c, rho=rho)
        x .= x .- alpha .* g
    end
    return x
end

# Zapis historii wyników
function optimize_armijo_with_history(cost, grad!, x0; maxiter=100, tol=1e-6,
            c=0.1, rho=0.5)
    x = copy(x0)
    history = Float64[]
    for k in 1:maxiter
```

```
        push!(history, cost(x))
        x = optimize_armijo_step(cost, grad!, x; maxiter=1, tol=tol, c=c, rho=rho)
    end
    push!(history, cost(x))
    return x, history
end

# Porównanie 6 kombinacji parametrów Armijo vs stały krok.
armijo_configs = [
    (c=0.1,  rho=0.1,  label="Armijo c=0.1  =0.1", color=:red),
    (c=0.1,  rho=0.8,  label="Armijo c=0.1  =0.8", color=:blue),
    (c=0.1, rho=0.08,  label="Armijo c=0.1  =0.08", color=:cyan),
    (c=0.5, rho=0.1,  label="Armijo c=0.5  =0.1", color=:orange),
    (c=0.5, rho=0.8,  label="Armijo c=0.5  =0.8", color=:purple),
    (c=0.5,  rho=0.08,  label="Armijo c=0.5  =0.08", color=:gray),
]

MAXITER = 100

function mean_history(histories)
    return [mean(h[k] for h in histories) for k in 1:(MAXITER+1)]
end

using Statistics

# Stały krok
fixed_histories = [optimize_with_history(f, grad_f!, x0; step=0.01,
        maxiter=MAXITER) |> last for x0 in starting_points]
fixed_mean = mean_history(fixed_histories)

p3 = plot(0:MAXITER, fixed_mean, label="Stały krok 0.01", linewidth=2,
          linestyle=:dash, color=:black,
          title="Zbieżność: stały krok vs Armijo (uśrednione po 10 punktach)",
          xlabel="Iteracja", ylabel="f(x)", size=(700, 500))

for cfg in armijo_configs
    arm_histories = [optimize_armijo_with_history(f, grad_f!, x0;
                         maxiter=MAXITER, c=cfg.c, rho=cfg.rho) |> last
                     for x0 in starting_points]
    arm_mean = mean_history(arm_histories)
    plot!(p3, 0:MAXITER, arm_mean, label=cfg.label, linewidth=1.5, color=cfg.color)
end
```

```
display(p3)
```

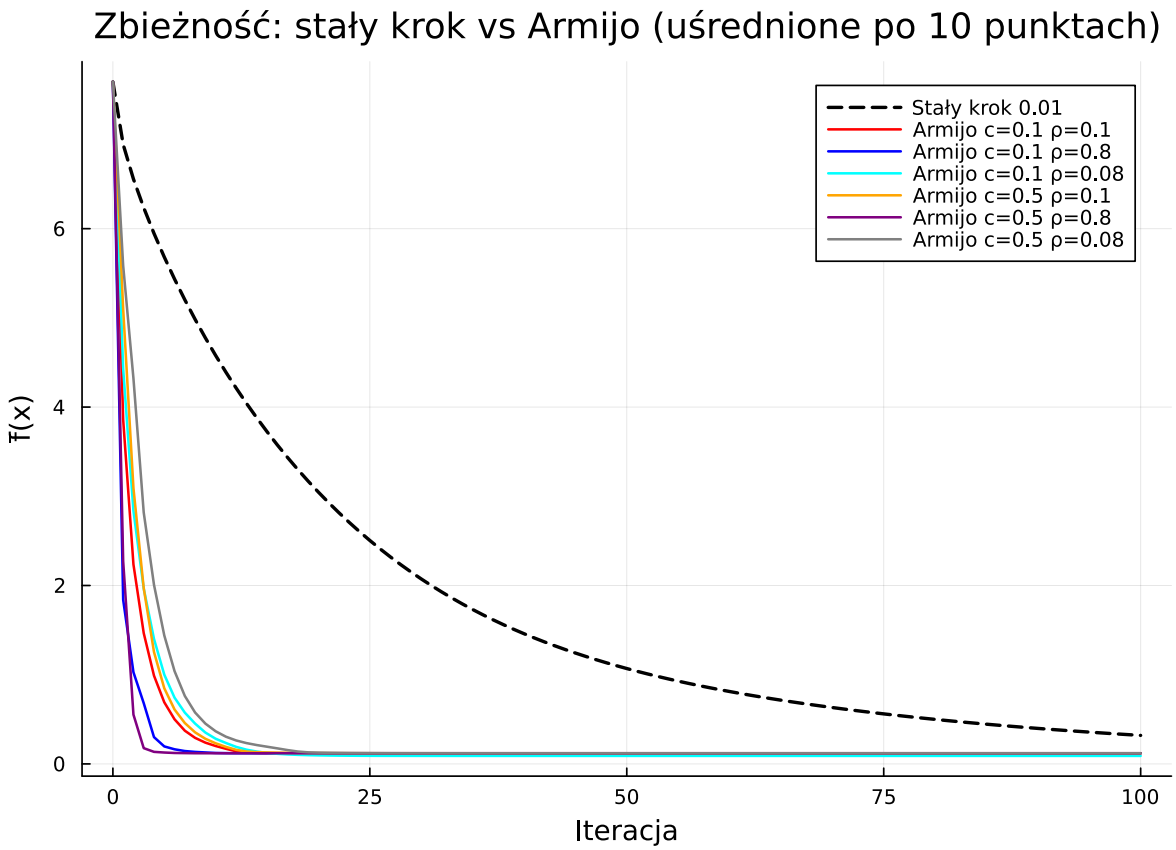

W metodzie wystarczającym spadkiem Armijo widzimy znaczną poprawę działania względem metody o stałym kroku. Metoda ta wymaga znacznie mniejszej ilości iteracji, stąd na wykresie histori dla 100 iteracji różnicy w działaniu pomiędzy poszczególnymi kombinacjami parametrów nie widać (bardzo szybkie wypłaszczenie).

Dlatego w celu porównania zestawów parametrów przedstawiamy wykres dla maxymalnej ilości iteracji = 10.

```
MAXITER = 10

armijo_configs = [
    (c=0.1,  rho=0.1,  label="Armijo c=0.1  =0.1", color=:red),
    (c=0.1,  rho=0.8,  label="Armijo c=0.1  =0.8", color=:blue),
    (c=0.1, rho=0.08,  label="Armijo c=0.1  =0.08", color=:cyan),
    (c=0.5, rho=0.1,  label="Armijo c=0.5  =0.1", color=:orange),
    (c=0.5, rho=0.8,  label="Armijo c=0.5  =0.8", color=:purple),
```

```
    (c=0.5,  rho=0.08,  label="Armijo c=0.5  =0.08", color=:gray),
]

p4 = plot(title="Zbieżność Armijo (uśrednione po 10 punktach)",
        xlabel="Iteracja", ylabel="f(x)", legend=:topright)

for cfg in armijo_configs
    arm_histories = [optimize_armijo_with_history(f, grad_f!, x0;
                        maxiter=MAXITER, c=cfg.c, rho=cfg.rho) |> last
                    for x0 in starting_points]
    arm_mean = mean_history(arm_histories)
    plot!(p4, 0:MAXITER, arm_mean, label=cfg.label, linewidth=1.5, color=cfg.color)
end

display(p4)
```

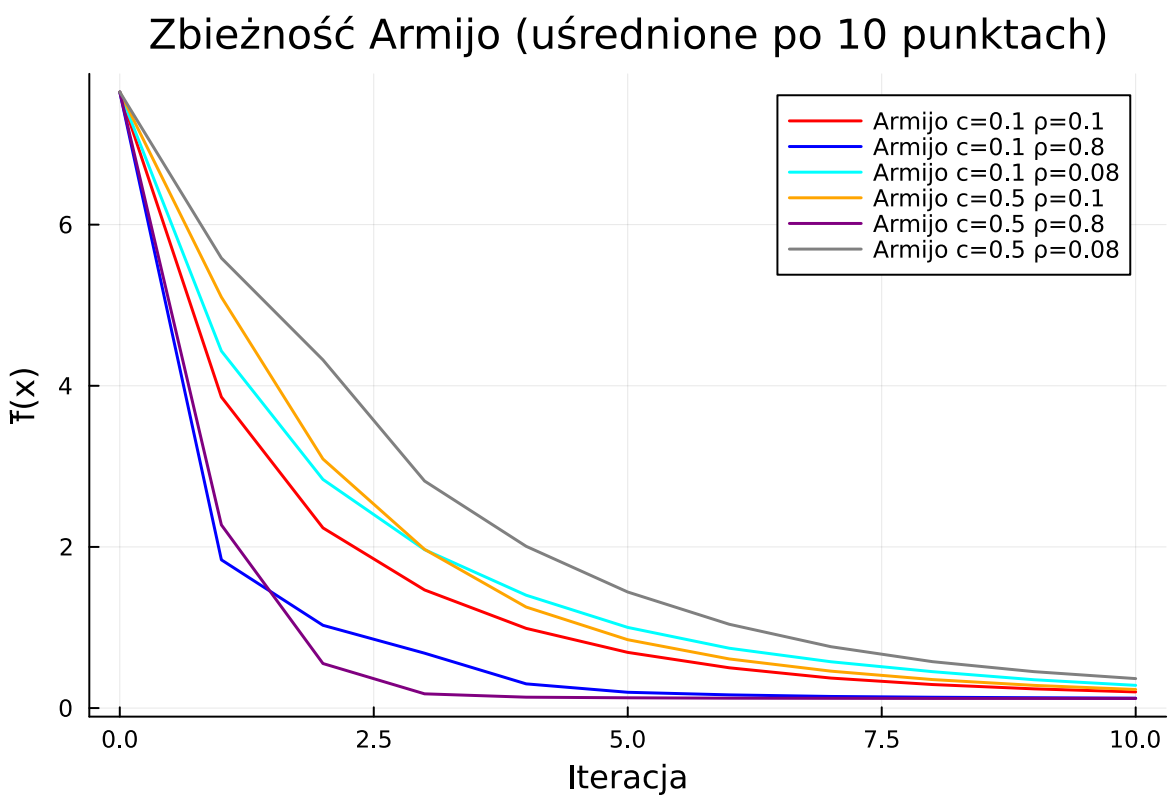


```
# Jeszcze dla czytelności rozdzielmy wykresy dla c=0.1 i c=0.5
plots = []
```

```julia
p51 = plot(title="Zbieżność Armijo (uśrednione po 10 punktach)",
        xlabel="Iteracja", ylabel="f(x)", legend=:topright)
for cfg in [ x for x in armijo_configs if x.c == 0.1 ]
    arm_histories = [optimize_armijo_with_history(f, grad_f!, x0;
                         maxiter=MAXITER, c=cfg.c, rho=cfg.rho) |> last
                     for x0 in starting_points]
    arm_mean = mean_history(arm_histories)
    plot!(p51, 0:MAXITER, arm_mean, label=cfg.label, linewidth=1.5, color=cfg.color)
end
push!(plots, p51)

p52 = plot(title="Zbieżność Armijo (uśrednione po 10 punktach)",
        xlabel="Iteracja", ylabel="f(x)", legend=:topright)

for cfg in [ x for x in armijo_configs if x.c == 0.5 ]
    arm_histories = [optimize_armijo_with_history(f, grad_f!, x0;
                         maxiter=MAXITER, c=cfg.c, rho=cfg.rho) |> last
                     for x0 in starting_points]
    arm_mean = mean_history(arm_histories)
    plot!(p52, 0:MAXITER, arm_mean, label=cfg.label, linewidth=1.5, color=cfg.color)
end
push!(plots, p52)

print( length(plots) )

plot(plots...; layout=(1, 2), size=(1100, 500), xlabel="Iteracja", ylabel="f(x)")
```

```
2
```

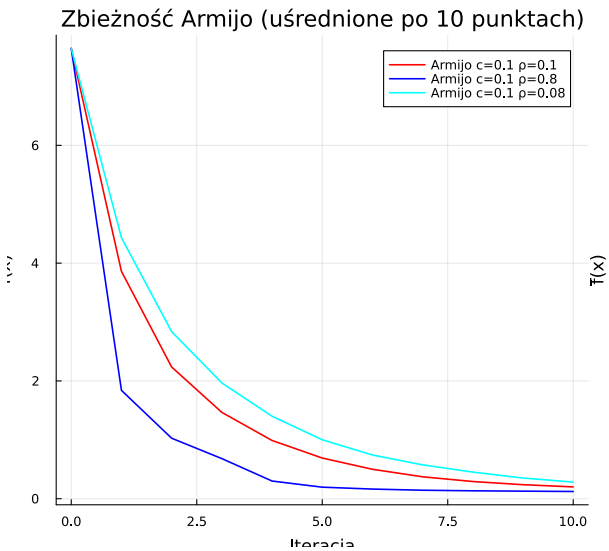

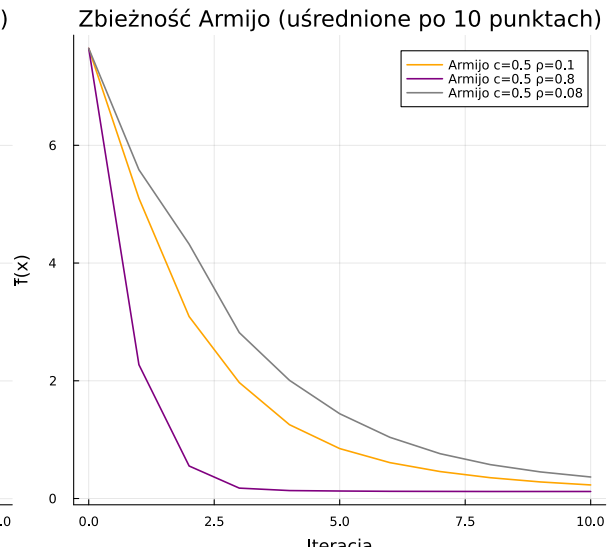

Wnioski

W metodzie wystarczającym spadkiem Armijo widzimy znaczną poprawę działania względem metody o stałym kroku. Osiąga dobre przybliżenie już w niewielkiej ilości kroków, około 10 w porównaniu ze 100.

Porównanie parametrów c oraz rho metody Armijo

- c - parametr odpowiadający za wielkość poprawy potrzebnej do zaakceptowania kroku
- rho -parametr odpowiadający za szybkość zmiany kroku podczas backtrackingu

Ze względu na rho: - Rho = 0.8 - osiąga najlepsze wyniki względem pozostałych testowanych wartości - Rho = 0.1 oraz 0.08 - czyli za równo wyższe i niższe osiągają gorsze wyniki

Ze wzglęgu na c: - Różnica jest mniej jednoznaczna jednak, dla c = 0.1 wyniki są nieco lesze niż dla c = 0.5.

Choć warto zaznaczyć że wszyskie testowane zestawy osiągają dobre i dość zbliżone do siebie wyniki.

Zadania na 5.0:

```julia
MAXITER = 10

# bracket_minimum z wykładu
function bracket_minimum(f, x=0.0; s=1e-2, k=2.0, n=10)
    a, ya = x, f(x)
    b, yb = a + s, f(a + s)
    if yb > ya
        a, b = b, a
        ya, yb = yb, ya
        s = -s
    end
    for i in 1:n
        c, yc = b + s, f(b + s)
        if yc > yb
            return a < c ? (a, c) : (c, a)
        end
        a, ya, b, yb = b, yb, c, yc
        s *= k
    end
    return (NaN, NaN)
end

# Złoty podział w przedziale [a, b]
function golden_section_search(f, a, b; tol=1e-8, maxiter=200)
    phi = (sqrt(5.0) - 1.0) / 2.0
    c = b - phi * (b - a)
    d = a + phi * (b - a)
    for _ in 1:maxiter
        abs(b - a) < tol && break
        if f(c) < f(d)
            b = d
        else
            a = c
        end
        c = b - phi * (b - a)
        d = a + phi * (b - a)
    end
    return (a + b) / 2.0
end

# Przeszukiwanie liniowe: auto-bracket + złoty podział
function bracket_line_search(cost, x, g; s=1e-2, k=2.0, n=20)
```

```
    d = -g
    phi_1d(alpha) = cost(x .+ alpha .* d)
    a_br, b_br = bracket_minimum(phi_1d, 0.0; s=s, k=k, n=n)
    if isnan(a_br)
        return 0.0
    end
    a_br = max(a_br, 0.0)
    return golden_section_search(phi_1d, a_br, b_br)
end

# Optymalizacja z auto-bracketingiem
function optimize_bracket_step(cost_data, grad_data, x0;
        step=nothing, maxiter=100, tol=1e-6, s=1e-2, k=2.0, n=20)
    x = copy(x0)
    g = similar(x)
    !isfinite(cost_data(x)) && error("cost_data(x0) is not finite.")
    for _ in 1:maxiter
        grad_data(g, x)
        any(!isfinite, g) && error("Gradient became non-finite")
        norm(g) < tol && return x
        alpha = bracket_line_search(cost_data, x, g; s=s, k=k, n=n)
        x .= x .- alpha .* g
    end
    return x
end

function optimize_bracket_with_history(cost, grad!, x0; maxiter=100,
            tol=1e-6, s=1e-2, k=2.0, n=20)
    x = copy(x0)
    history = Float64[]
    for _ in 1:maxiter
        push!(history, cost(x))
        x = optimize_bracket_step(cost, grad!, x;
                maxiter=1, tol=tol, s=s, k=k, n=n)
    end
    push!(history, cost(x))
    return x, history
end

# zestawy parametrów bracketingu
bracket_configs = [
    (s=3, k=1.0, n=5, label="s=3 k=1.0 n=5", color=:red),
```

```
    (s=0.1, k=3.0, n=5, label="s=0.1 k=3.0 n=5", color=:pink),
    (s=2, k=1.0, n=10, label="s=2 k=1.0 n=10", color=:green),
    (s=0.01, k=2.0, n=4, label="s=0.01 k=2.0 n=4", color=:orange),
    (s=0.5, k=2.0, n=3, label="s=0.5 k=2.0 n=3", color=:cyan),
    (s=0.001, k=3.0, n=20, label="s=0.001 k=3.0 n=20", color=:brown),
    (s=3, k=0.5, n=20, label="s=3 k=0.5 n=20", color=:magenta),
    (s=0.1, k=10, n=5, label="s=0.1 k=10 n=5", color=:lime),
    (s=2, k=1.0, n=10, label="s=2 k=1.0 n=10", color=:gray),
    (s=0.001, k=2.0, n=5, label="s=0.001 k=2.0 n=5", color=:lightgreen),
    (s=0.001, k=2.0, n=10, label="s=0.001 k=2.0 n=10", color=:lightblue),
]

p6 = plot(title="Auto-bracket vs bracket [0, 1] (uśrednione po 10 punktach)",
        xlabel="Iteracja", ylabel="f(x)", size=(700, 500))

arm_ref_histories = [optimize_armijo_with_history(f, grad_f!, x0;
            maxiter=MAXITER, c=0.1, rho=0.8) |> last
                     for x0 in starting_points]
plot!(p6, 0:MAXITER, mean_history(arm_ref_histories),
      label="Armijo c=0.1  =0.8", linewidth=2, color=:blue)

for cfg in bracket_configs
    br_histories = [optimize_bracket_with_history(f, grad_f!, x0;
                        maxiter=MAXITER, s=cfg.s, k=cfg.k, n=cfg.n) |> last
                    for x0 in starting_points]
    br_mean = mean_history(br_histories)
    plot!(p6, 0:MAXITER, br_mean, label=cfg.label, linewidth=1.5, color=cfg.color)
end

display(p6)
```

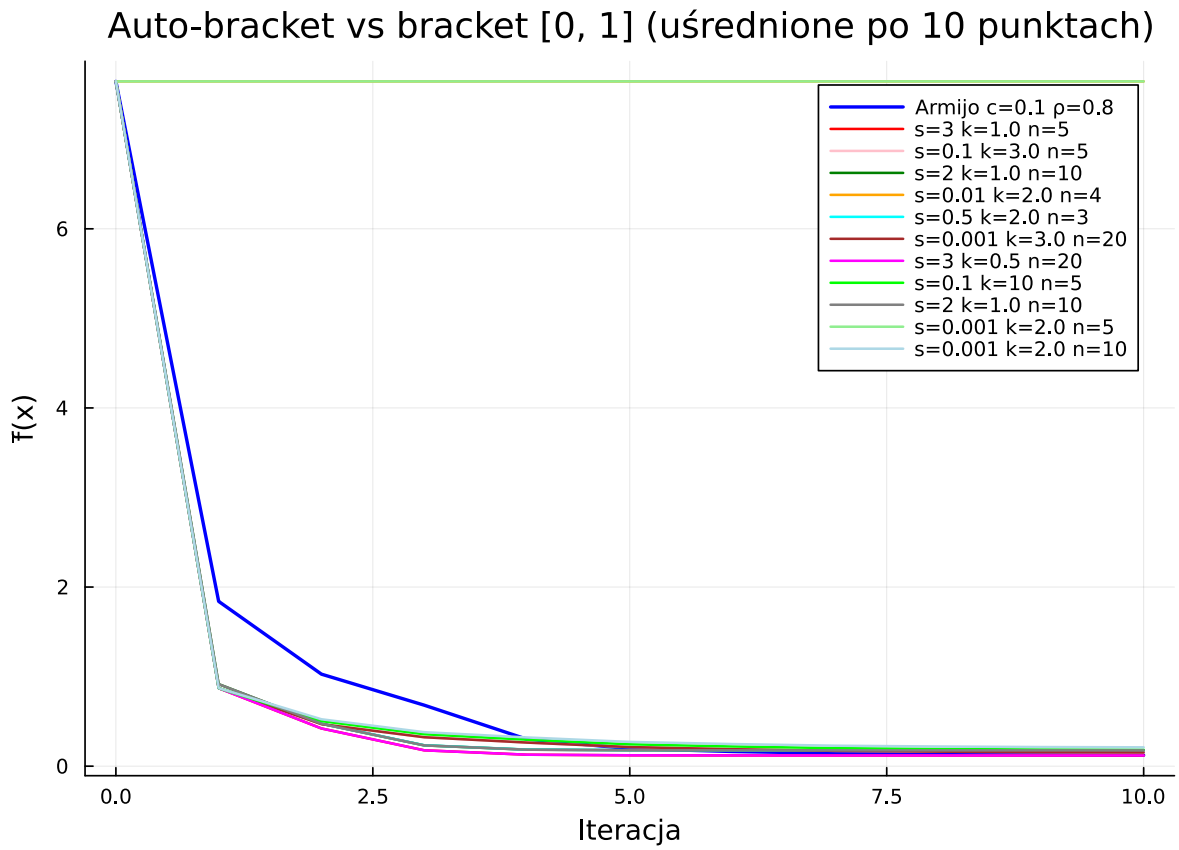


```
p6 = plot(title="Auto-bracket vs bracket [0, 1] w skali logarytmicznej",
        xlabel="Iteracja", ylabel="f(x)", size=(700, 500))

arm_ref_histories = [optimize_armijo_with_history(f, grad_f!, x0;
            maxiter=MAXITER, c=0.1, rho=0.8) |> last
                     for x0 in starting_points]
plot!(p6, 0:MAXITER, mean_history(arm_ref_histories),
      label="Armijo c=0.1  =0.8", linewidth=2, color=:blue)

for cfg in bracket_configs
    br_histories = [optimize_bracket_with_history(f, grad_f!, x0;
                        maxiter=MAXITER, s=cfg.s, k=cfg.k, n=cfg.n) |> last
                    for x0 in starting_points]
    br_mean = mean_history(br_histories)
    plot!(p6, 0:MAXITER, br_mean, label=cfg.label, linewidth=1.5, color=cfg.color, yscale=:lo
end

display(p6)
```

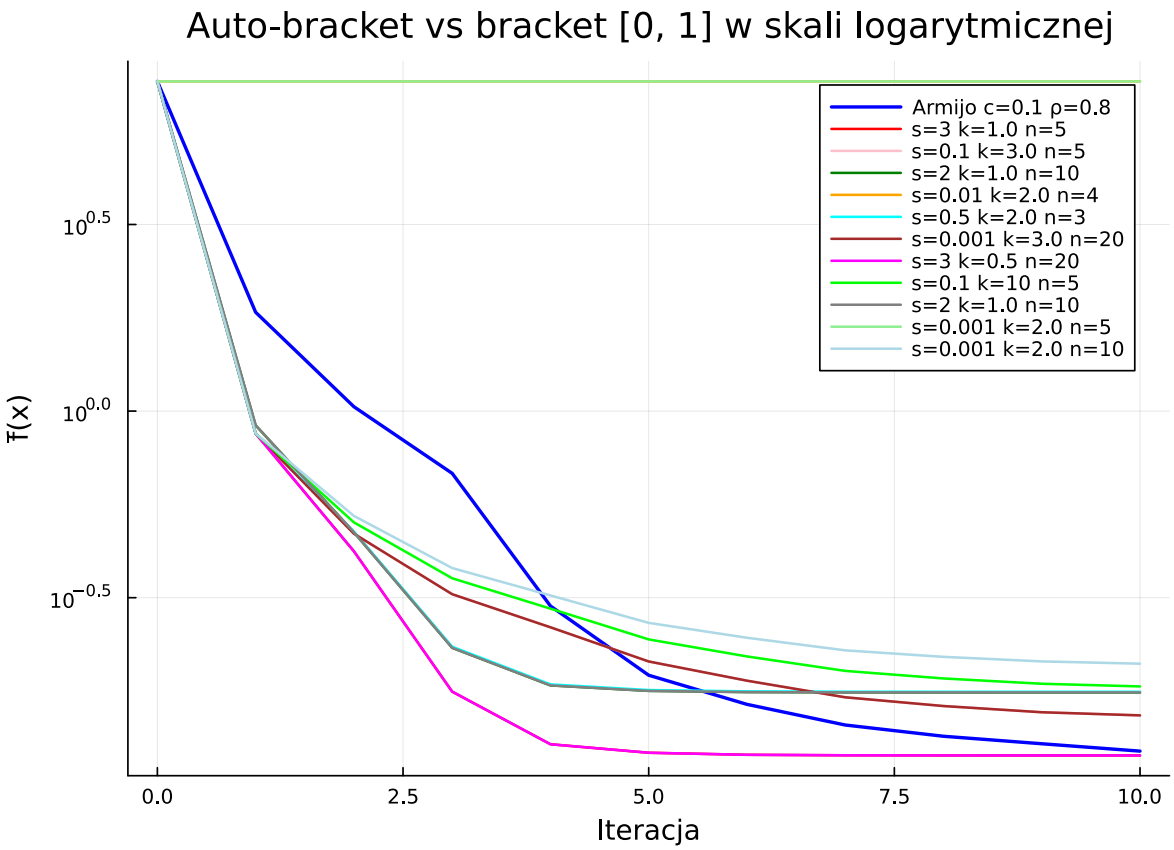

Wnioski

Metoda z auto-bracket osiąga zbieżność jeszcze szybciej niż prezentowana wcześniej Armijo ze sztywnym bracketem [0, 1]. Jednak różnica na obserwowanym przykładzie nie jest już aż tak drastyczna.

Porównanie wpływu parametrów s, k, n

- s - początkowy krok
- k - współczynnik powiększania kroku
- n - max ilość iteracji rozszerzeń przedziału w bracket_minimum

Mimo przetesowania kilku kombinacji wartości s, k, n różnice w wynikach dla testowanego przykładu są bardzo małe, a wręcz pomijanle.

Chociaż należy zauważyć, że łącząc niefortunny dobór parametrów s i k (w zaobserwowanym przypadku s = 0.001, k = 2.0) z małą ilością iteracji n = 5 możemy utracić zbierzność.